

Análisis E-Commerce UK Retailer — Documentación Técnica del Proyecto

Table of Contents

Análisis de E-Commerce UK Retailer

Portfolio Data Analyst — Documentación Técnica del Proyecto

Dataset: Kaggle E-Commerce Data (carrie1) · Período: Diciembre 2010 – Diciembre 2011 · UK Retailer

Dataset limpio post-ETL: 536.641 filas · 14 tablas relacionales · Revenue neto: £9.770.920

1. Resumen Ejecutivo

Propósito del proyecto. Análisis completo del ciclo de datos de un retailer online del Reino Unido de artículos de decoración del hogar: desde el dataset crudo con 541.909 transacciones hasta un modelo relacional en star schema de 14 tablas, el análisis de 11 hipótesis de negocio y un dashboard interactivo. El proyecto demuestra el flujo de trabajo completo de un Data Analyst: exploración, limpieza, modelado, análisis y visualización.

Hallazgos principales

- **£9.77M** de revenue neto en el período (£9.770.920).
- **Noviembre 2011** es el mes pico con **£1.45M — 1.8× el promedio mensual**.
- El **74.4% del revenue** ocurre en la franja horaria **10:00–15:00h**.
- El **top 20% de clientes** (866 identificados) genera el **74.6% del revenue** (Pareto confirmado).
- **6 países** operan como mayoristas internacionales, con tickets **3.3–7.0× superiores** al baseline UK.
- La **tasa de cancelación** es estructuralmente estable: media **14.53%**, CV **10.8%**.
- El **dataset original mezcla 3 fuentes distintas** en un solo archivo — separado en 9 tablas con lógicas de negocio independientes.

Stack tecnológico

Categoría	Tecnología	Uso en el proyecto
Lenguaje	Python 3.11	Todas las notebooks y la app Dash
Datos	pandas · numpy	Transformación, limpieza,

Categoría	Tecnología	Uso en el proyecto
Visualización	matplotlib · seaborn	modelado y análisis Gráficos de las notebooks de análisis (NB1–NB5)
Dashboard	Plotly · Dash	Dashboard web interactivo con callbacks reactivos
Base de datos	SQLite (sqlite3)	Validación cruzada de KPIs en NB5
Exportación	openpyxl	Excel con 11 hojas en NB3 y 6 hojas en NB5
Modelo ER	DBML / dbdiagram.io	Diagrama relacional — 14 tablas, 27 relaciones

2. Arquitectura del Proyecto

Pipeline de datos

El proyecto sigue un pipeline lineal de 6 etapas. Cada notebook produce los archivos que consume la siguiente: **el orden de ejecución es estricto.**

Notebook	Etapas	Descripción	Output
NB1 — EDA	Análisis exploratorio	Exploración estadística del dataset crudo. 13 hallazgos documentados con severidad.	12 assets .png
NB2 — Análisis Estructural	Separación en 9 tablas	Demuestra con evidencia cuantitativa por qué el dataset mezcla 3 fuentes. Define los 2 filtros de clasificación.	5 assets .png
NB3 — ETL	Limpieza y transformación	Pipeline completo: tipos, estandarización, deduplicación, nulos, outliers, columnas calculadas.	9 CSVs + Excel (11 hojas)
NB4 — Modelado Relacional	Star Schema híbrido	Construye las 14 tablas del modelo dimensional. 27	14 CSVs en data/model/

Notebook	Etapas	Descripción	Output
		relaciones verificadas con 0 FKs huérfanas.	
NB5 — Análisis y KPIs	11 hipótesis + validación SQL	Análisis completo con métricas y validación cruzada Python vs SQL.	Excel KPIs (6 hojas)
NB6 — Dashboard	Plotly Dash interactivo	App web con 4 páginas y filtros reactivos. Lee los CSVs del modelo en tiempo real.	App en localhost:8050

Estructura de carpetas

Carpeta / Archivo	Contenido
data/data.csv	Dataset original (541.909 filas) — nunca se modifica
data/clean/ (9 CSVs + Excel)	Salida del ETL — tablas limpias con columnas calculadas
data/model/ (14 CSVs)	Modelo relacional — fact tables + dimensiones
data/kpis/analisis_kpis.xlsx	KPIs y conclusiones de las 11 hipótesis (6 hojas)
notebooks/ (6 .ipynb)	Pipeline completo NB1 – NB6
assets/ (27 .png)	Gráficos generados por las notebooks
modelo_relacional.dbml	Schema DBML para dbdiagram.io (14 tablas, 27 Ref:)
docs/	Documentación técnica (Word + PDF), modelado y diagrama de flujo
La carpeta data/ no se versiona en el repositorio por su tamaño (~200 MB). Los CSVs se regeneran ejecutando las notebooks en orden (ver sección 7).	

3. Modelo de Datos

3.1 Las 9 tablas del ETL

El dataset original mezcla 3 fuentes con lógicas de negocio distintas. La Notebook 2 demuestra con evidencia cuantitativa **por qué no pueden analizarse como una sola tabla**.

Tabla	Filas	Descripción
dim_ventas	532.328	Ventas y cancelaciones de productos. Tabla principal

Tabla	Filas	Descripción
		del análisis. Incluye IsCancellation, IsGuest, Revenue, Year, Month, DayOfWeek, Hour.
inventory_adjustments	1.324	Bajas de inventario internas. UnitPrice siempre £0, CustomerID siempre nulo, Quantity siempre negativa.
dim_envios	2.110	Cargos de envío POST, DOT y C2. Revenue total £279.462 (2.73% del revenue de ventas).
dim_ajustes_contables	570	Ajustes manuales M y bad debt B. Incluye flag para los 2 asientos de precio negativo.
dim_conceptos_directo	97	Descuentos D, comisión ONG (CRUK) y PADS. CustomerID siempre presente.
dim_conceptos_indirecto	96	Comisiones Amazon (AMAZONFEE) y muestras S. CustomerID 100% nulo.
dim_conceptos_mixto	37	Cargos bancarios (BANK CHARGES). CustomerID mixto: 32% presente, 68% nulo.
dim_channel_external	45	Canal Dotcomgiftshop/eBay (16 SC con prefijo DCGS). CustomerID 100% nulo.
dim_voucher	34	Vales de regalo GIFT_0001_XX. Precio ≈ 85% del valor nominal.

3.2 Star Schema híbrido — modelo relacional

La Notebook 4 construye el modelo relacional sobre las 9 tablas del ETL. **27 relaciones verificadas con 0 FKs huérfanas.**

Tabla	Tipo	Filas	Decisión de diseño clave
fact_ventas	Fact table	532.328	PK subrogada SaleLineID. CustomerID nulo →

Tabla	Tipo	Filas	Decisión de diseño clave
fact_ajustes_inventario	Fact table	1.324	-1. InvoiceDate → DateKey FK. Elimina columnas 100% constantes (Country, UnitPrice, CustomerID).
dim_producto	Dimensión	3.926	UNION de SC de ventas + ajustes. Description canónica.
dim_cliente	Dimensión	4.364	Segmentos Mayorista/Retail/Guest. Registro CID=-1 para ventas anónimas.
dim_fecha	Dimensión	396	Generada con pd.date_range. DateKey int YYYYMMDD. Incluye días sin actividad.
dim_pais	Dimensión	38	PK natural Country — única excepción al patrón subrogado.
dim_concepto	Dimensión	32	Lookup de los 32 StockCodes admin de las 7 tablas operativas.
7 tablas operativas	Operativas	2.989	PKs subrogadas. DateKey FK. Columnas 100% constantes eliminadas.

Normalización. Todas las dimensiones cumplen 3FN. Excepciones conscientes documentadas: MonthNameES, QuarterName y DayOfWeekES en dim_fecha (estándar BI); TipoConcepto en dim_concepto. Métricas desnormalizadas en dim_producto y dim_cliente por performance (n_ventas, revenue_total, etc.).

4. Análisis de Hipótesis

Se formularon **11 hipótesis** de negocio sobre los datos limpios post-ETL, validadas con dos enfoques paralelos: pandas en Python y queries SQL sobre SQLite. Las hipótesis cubren 5 bloques del negocio: revenue y estacionalidad, clientes, productos, geografía y operaciones.

4.1 Resumen de resultados

ID	Bloque	Hipótesis	Veredicto
H-01	Revenue y estacionalidad	Q4 (oct–dic) concentra > 40% del revenue anual	✗ No confirmada
H-02	Revenue y estacionalidad	La franja 10:00–15:00h concentra > 70% del revenue diario	✓ Confirmada
H-03	Clientes	El 20% de los clientes identificados genera el 74% del revenue (Pareto)	✓ Confirmada
H-04	Clientes	La frecuencia de compra no predice el ticket promedio	✓ Confirmada
H-05	Clientes	El segmento Guest tiene ticket similar al identificado	⚠ Resultado inesperado
H-06	Productos	El top 50 productos concentra > 20% del revenue	✓ Confirmada
H-07	Productos	Los 104 SC de baja se dieron de baja en un período concentrado	✓ Confirmada
H-08	Geografía	Netherlands y Australia son mayoristas (ticket 5–7× UK)	✓ Confirmada
H-09	Geografía	Los clientes internacionales pesan < 10% de la base pero > 15% del revenue	✓ Confirmada
H-10	Operaciones	La tasa de cancelación (~14.5% de facturas) es estable sin	✓ Confirmada

ID	Bloque	Hipótesis	Veredicto
H-11	Operaciones	estacionalidad Los costos de envío representan < 3% del revenue de ventas	✓ Confirmada

Balance: 9 confirmadas · 1 no confirmada (H-01) · 1 resultado inesperado (H-05).

4.2 Detalle por bloque temático

Bloque A — Revenue y estacionalidad

H-01 · Q4 concentra > 40% del revenue anual - *Validación:* agrupar `dim_ventas` por trimestre (columnas `Year`, `Month`, `Revenue`); excluir dic-2011 (solo 9 días de datos). Calcular revenue Q4 (oct+nov 2011) sobre el total ene–nov 2011. - *Resultado:* Q4 (oct+nov) = **28.9%** del año. La hipótesis se refuta en los términos planteados — el 40% era demasiado agresivo. Sin embargo, nov-2011 (£1.45M) es el máximo mensual, ~1.8× el promedio. - *Veredicto:* **✗ No confirmada** (se reformula: “noviembre es el mes de mayor revenue, con ~1.8× el promedio mensual”).

H-02 · La franja 10:00–15:00h concentra > 70% del revenue diario - *Validación:* agrupar por Hour (filtro `IsCancellation = False`, `UnitPrice > 0`). Calcular % de revenue en la franja 10–15h sobre el total. - *Resultado:* franja 10–15h = **74.4%** del revenue total. Las 6 horas centrales generan casi 3 de cada 4 libras facturadas. - *Veredicto:* **✓ Confirmada**.

Bloque B — Clientes

H-03 · El 20% de los clientes identificados genera el 74% del revenue (Pareto) - *Validación:* ordenar clientes por revenue descendente (filtro `IsGuest = False`, `IsCancellation = False`, `UnitPrice > 0`). Calcular revenue acumulado del top 20%. - *Resultado:* top 20% (**866 clientes**) — **74.6%** del revenue identificado. Base de clientes extremadamente concentrada. - *Veredicto:* **✓ Confirmada**.

H-04 · La frecuencia de compra no predice el ticket promedio - *Validación:* por cliente, calcular `n_pedidos` (`InvoiceNo` únicos) y `ticket_promedio`. Correlación de Pearson y Spearman entre ambas. - *Resultado:* Pearson $r = -0.005$ · Spearman $r = 0.076$. Correlación estadísticamente nula: frecuencia y valor unitario son dimensiones independientes del cliente. - *Veredicto:* **✓ Confirmada**.

H-05 · El segmento Guest tiene ticket similar al identificado - *Validación:* `ticket promedio = Revenue / InvoiceNo` únicos, para `IsGuest = True` vs `False`. - *Resultado:* `ticket Guest = £1.101` vs `ticket identificado £475` — **2.3×**; comparado solo contra Retail (£366), el ratio es **3.0×**. **El resultado es el opuesto al esperado:** los Guest gastan más del doble por factura. Probable explicación: mayoristas que compran sin registrarse, o compras presenciales de alto volumen. - *Veredicto:* **⚠ Resultado inesperado** (refuta la hipótesis original).

Bloque C — Productos

H-06 · El top 50 productos concentra > 20% del revenue - *Validación:* agrupar por StockCode, sumar Revenue, ordenar descendente. Calcular % acumulado para top 10 / 50 / 100 / 200. - *Resultado:* Top 10 SC = **9.5%** · Top 50 SC = **22.1%** · Top 100 = **32.9%**. El **1.3% del catálogo** (50 de 3.791 SC activos) genera más de 1 de cada 5 libras. - *Veredicto:* ✓ **Confirmada**.

H-07 · Los 104 SC de baja se dieron de baja en un período concentrado - *Validación:* identificar los 104 SC exclusivos de inventory_adjustments (nunca vendidos). Distribuir sus fechas de baja por mes. - *Resultado:* **72.1%** de las bajas en 3 meses: abril 2011 (37), enero 2011 (25) y marzo 2011 (13). Fue una limpieza planificada de inventario obsoleto en el primer semestre, no una reducción gradual. - *Veredicto:* ✓ **Confirmada**.

Bloque D — Geografía

H-08 · Netherlands y Australia son mayoristas (ticket 5–7× UK) - *Validación:* por país, calcular ticket promedio (Revenue/InvoiceNo), unidades por pedido y clientes únicos. Comparar el ratio de ticket vs baseline UK. - *Resultado:* Netherlands: ticket **£3.053 (7.0× UK)**, 9 clientes. Australia: **£2.466 (5.6× UK)**, 9 clientes. En total, **6 países mayoristas:** NL (7.0×), AU (5.6×), SG (5.2×), JP (4.5×), LB (3.9×), Israel (3.3×). Baseline UK: £437/ticket. - *Veredicto:* ✓ **Confirmada**.

H-09 · Los clientes internacionales pesan < 10% de la base pero > 15% del revenue - *Validación:* calcular % de clientes internacionales sobre total y % de revenue internacional sobre total. Comparar revenue per cápita UK vs internacional. - *Resultado:* internacional = **9.6% de clientes – 17.1% del revenue – 1.9× per cápita** vs UK. Un cliente internacional vale casi el doble que uno de UK en revenue. - *Veredicto:* ✓ **Confirmada**.

Bloque E — Operaciones

H-10 · La tasa de cancelación (~14.5% de facturas) es estable sin estacionalidad - *Validación:* tasa mensual = facturas únicas con cancelación / total de facturas únicas por mes (medir sobre InvoiceNo, no sobre filas). Calcular el coeficiente de variación (CV < 20% = estable). - *Resultado:* rango 12.2%–18.2% · media **14.53%** · CV **10.8%**. La tasa es estable. Nota: el mes de mayor demanda (nov-2011) tiene la tasa MÁS BAJA (12.2%) — el volumen extra de temporada alta no genera más cancelaciones proporcionalmente. - *Veredicto:* ✓ **Confirmada**.

H-11 · Los costos de envío representan < 3% del revenue de ventas - *Validación:* Revenue de dim_envios / Revenue de dim_ventas × 100. Desglosar por StockCode (POST vs DOT vs C2). - *Resultado:* £279.462 / £10.246.821 = **2.73%**. Los envíos no son una partida relevante para el análisis de P&L. - *Veredicto:* ✓ **Confirmada**.

5. Hallazgos Destacados

Cuatro resultados merecen profundización por su relevancia estratégica:

H-05 — El cliente Guest gasta ~2× más por factura que el identificado promedio. Ticket Guest £1.101 vs £475 del ticket identificado (2.3×), y 3.0× vs el ticket retail (£366). El segmento

anónimo se comporta como mayorista — probablemente distribuidores que compran sin registrarse. Es una oportunidad de captación. Próximo paso: cruzar con Country y Quantity por pedido para discriminar el origen del segmento.

H-10 — Noviembre (pico de ventas) tiene la tasa de cancelación MÁS BAJA. La tasa media es 14.53% con CV 10.8% (estable). El hallazgo inesperado: noviembre 2011, el mes de mayor revenue, tiene la tasa más baja del período (12.2%). Los clientes de temporada alta son más decididos, lo que permite proyectar el revenue neto de noviembre con alta confianza. (La tasa real sobre facturas es 14.53%, no el 1.65% del EDA inicial, que medía líneas en vez de facturas.)

H-04 — Frecuencia y valor unitario son dimensiones independientes del cliente. Pearson $r = -0.005$: correlación nula. Existen dos arquetipos con estrategias distintas: el cliente recurrente de bajo ticket (retener con frecuencia) y el cliente esporádico de alto ticket (retener con calidad del producto).

Estructura del dataset — 3 fuentes mezcladas en 1 archivo. El dataset combina ventas, ajustes de inventario, cargos de envío, ajustes contables, conceptos de canal externo y vouchers sin distinguirlos. Calcular cualquier métrica sin separarlos produce resultados incorrectos. La Notebook 2 lo demuestra con 3 métricas independientes (% CID nulo, revenue neto y países únicos): 3 perfiles completamente distintos por familia de StockCode.

6. Dashboard Interactivo

Dashboard Plotly Dash (Notebook 6). App web Python conectada a los datos reales del modelo relacional. Los filtros recalculan los DataFrames en tiempo real.

- Lee los CSVs de data/clean/ al arrancar — datos reales, no hardcodeados.
- Callbacks reactivos: cuando el usuario mueve un filtro, Python recalcula y devuelve el gráfico actualizado con Plotly.
- **4 páginas:**
 - **Resumen Ejecutivo** — KPIs globales, revenue mensual, distribución horaria, composición del revenue, cancelación mensual.
 - **Clientes** — Pareto acumulado, ticket por segmento, frecuencia, top 10 (filtro Todos/Mayorista/Retail).
 - **Productos** — concentración del catálogo, top SKUs, tabla detallada, bajas de inventario.
 - **Geografía y Operaciones** — países por revenue, ratio vs UK, cancelación, composición por origen (filtro por tipo de mercado).

Para correr el dashboard: ejecutar todas las celdas de la Notebook 6 → abrir `http://localhost:8050` en el browser.

7. Instalación y Uso

Requisitos

- Python 3.11+
- Jupyter Notebook o JupyterLab
- Ver `requirements.txt` para el listado completo de dependencias

Dependencias principales

Librería	Versión mínima	Usada en
pandas	2.0+	Todas las notebooks
numpy	1.24+	NB1, NB2, NB4, NB5
matplotlib / seaborn	3.7+ / 0.12+	NB1–NB5
scipy	1.11+	NB1 (tests estadísticos)
openpyxl	3.1+	NB3, NB5 (exportar Excel)
plotly	5.18+	NB6 (Dashboard Dash)
dash	2.14+	NB6 (app web interactiva)

Instalación rápida: `pip install -r requirements.txt`

Setup del dataset

El dataset original no se incluye en el repositorio por su tamaño. Para reproducir el proyecto:

1. Descargar `data.csv` de [Kaggle — E-Commerce Data \(carrie1\)](#).
2. Crear la carpeta `data/` en la raíz del proyecto y colocar el archivo ahí (`data/data.csv`).
3. Ejecutar las notebooks en orden estricto.

Orden de ejecución

NB1 → NB2 → NB3 → NB4 → NB5 → NB6 — cada notebook consume los outputs de la anterior:

- NB1 y NB2 solo requieren `data/data.csv`.
- NB3 requiere que NB1 y NB2 hayan corrido.
- NB4 requiere los 9 CSVs de `data/clean/` (output de NB3).
- NB5 requiere los CSVs de `data/clean/` y `data/model/` (outputs de NB3 y NB4).
- NB6 requiere los CSVs de `data/clean/` (output de NB3).

Las carpetas `data/clean/`, `data/model/` y `data/kpis/` se generan automáticamente al ejecutar NB3, NB4 y NB5 (`os.makedirs(..., exist_ok=True)`).

8. Archivos Generados por el Pipeline

data/clean/ — 9 CSVs + 1 Excel (output NB3)

Archivo	Filas
dim_ventas.csv	532.328
inventory_adjustments.csv	1.324
dim_envios.csv	2.110
dim_ajustes_contables.csv	570
dim_conceptos_directo.csv	97
dim_conceptos_indirecto.csv	96
dim_conceptos_mixto.csv	37
dim_channel_external.csv	45
dim_voucher.csv	34
ecommerce_uk_clean.xlsx	Excel con 11 hojas (9 tablas + _resumen + _decisiones_etl)

data/model/ — 14 CSVs del modelo relacional (output NB4)

Tablas del star schema híbrido listas para SQL, Power BI o Looker Studio: fact_ventas (532.328 · PK SaleLineID), fact_ajustes_inventario (1.324 · PK AdjLineID), dim_producto (3.926 · PK ProductID), dim_cliente (4.364 · PK ClienteID · incluye CID=-1), dim_fecha (396 · PK DateKey), dim_pais (38 · PK Country natural), dim_concepto (32 · PK ConceptoID) y 7 tablas operativas normalizadas.

assets/ — 27 imágenes (outputs NB1-NB5)

12 de NB1 (completitud, distribuciones, Q-Q plots, correlaciones, hallazgos con severidad), 5 de NB2 (patrones SC, evidencia de unión, Pareto clientes, países atípicos, distribución de las 9 tablas), 2 de NB3 (impacto y decisiones del ETL), 2 de NB4 (integridad referencial, resumen del modelo) y 6 de NB5 (estacionalidad, clientes, productos, geografía, operativo, dashboard KPIs).

Proyecto: Portfolio Data Analyst — E-Commerce UK Retailer · Dataset: Kaggle E-Commerce Data (carrier1) · Período: dic 2010 – dic 2011

Michael Hans Evans · Data Analyst · Córdoba, Argentina · GitHub: MHEvans02